

Московский государственный университет имени М. В. Ломоносова



Факультет Вычислительной математики и Кибернетики  
Кафедра Математических Методов Прогнозирования

## **Методы оптимизации в машинном обучении**

**Отчет по практическому заданию №1.**

**«Методы градиентного спуска и Ньютона»**

Выполнил:  
магистр 1 курса 517 группы  
*Таскынов Анвар*

Москва, 2017

## Содержание.

<b>1 Постановка задания</b>	<b>2</b>
<b>2 Вывод формул</b>	<b>2</b>
<b>3 Эксперимент: Траектория градиентного спуска на квадратичной функции</b>	<b>4</b>
<b>4 Эксперимент: Зависимость числа итераций градиентного спуска от числа обусловленности и размерности пространства</b>	<b>7</b>
<b>5 Эксперимент: Сравнение методов градиентного спуска и Ньютона на реальной задаче логистической регрессии</b>	<b>9</b>
<b>6 (Бонусная часть) Эксперимент: Оптимизация вычислений в градиентном спуске</b>	<b>11</b>
<b>7 (Бонусная часть) Эксперимент: Стратегия выбора длины шага в градиентном спуске</b>	<b>12</b>
<b>8 (Бонусная часть) Эксперимент: Стратегия выбора длины шага в методе Ньютона</b>	<b>15</b>
<b>9 Выводы</b>	<b>18</b>

## 1 Постановка задания

В данном задании необходимо было реализовать методы градиентного спуска и Ньютона с различном выбором длины шага  $\alpha_k$ :

- константная длина шага:  $\alpha_k = \alpha_0$ .
- длина шага, удовлетворяющая условию Армихо с константой  $c \in (0, 0.5)$ :  $\phi_k(\alpha) \leq \phi_k(0) + c_1 \alpha \phi'_k(0)$ , где  $\phi_k(\alpha) = f(x_k + \alpha d_k)$ ,  $d_k$  — направление спуска.
- длина шага, удовлетворяющая сильным условиям Вульфа с константами  $c_1 \in (0, 0.5)$ ,  $c_2 \in (c_1, 1)$ .

В качестве критерия остановки выбран относительный квадрат нормы градиента:

$$\|\nabla f(x_k)\|_2^2 \leq \epsilon \|\nabla f(x_0)\|_2^2,$$

где  $\epsilon$  — необходимая точность,  $x_0$  — начальная точка.

Необходимо было провести эксперименты для сравнения данных методов. Среда выполнения: Python 3.

## 2 Вывод формул

В третьем пункте задания необходимо было представить функцию  $f(x)$  в матрично-векторной форме:

$$f(x) = \frac{1}{m} \sum_{i=1}^m \ln \left( 1 + \exp(-b_i \langle a_i, x \rangle) \right) + \frac{\lambda}{2} \|x\|_2^2.$$

Введем вектор  $1_m = (1, \dots, 1)^T$ , состоящий из  $m$  единиц,  $\odot$  - поэлементное умножение, тогда функцию  $f(x)$  можно представить следующим образом:

$$f(x) = \frac{1}{m} \left\langle 1_m, \ln \left( 1 + \exp(-b \odot Ax) \right) \right\rangle + \frac{\lambda}{2} \|x\|_2^2. \quad (1)$$

Скалярная функция  $\ln(1 + \exp(x))$  применяется к вектору поэлементно. Также нужно было найти градиент и гессиан данной функции в матрично-векторной форме.

$$\begin{aligned}
df(x) &= d\left(\frac{1}{m}\left\langle 1_m, \ln(1 + \exp(-b \odot Ax)) \right\rangle + \frac{\lambda}{2}\|x\|_2^2\right) = \\
&= -\frac{1}{m}\left\langle 1_m, \frac{\exp(-b \odot Ax) \odot b \odot Adx}{1 + \exp(-b \odot Ax)} \right\rangle + \lambda\langle x, dx \rangle = \\
&= -\frac{1}{m}\left\langle 1_m, \sigma(-b \odot Ax) \odot b \odot Adx \right\rangle + \lambda\langle x, dx \rangle = -\frac{1}{m}\left\langle \sigma(-b \odot Ax) \odot b, Adx \right\rangle + \lambda\langle x, dx \rangle = \\
&= \left\langle -\frac{1}{m}A^T(b \odot \sigma(-b \odot Ax)) + \lambda x, dx \right\rangle \quad (2)
\end{aligned}$$

Здесь  $\sigma(x) = \frac{1}{1+\exp(-x)}$  - сигмоидная функция. Продифференцируем сигмоидную функцию отдельно для дальнейшего вычисления гессиана:

$$\sigma'(x) = \left(\frac{1}{1 + \exp(-x)}\right)' = \frac{\exp(-x)}{(1 + \exp(-x))^2} = \sigma(x)(1 - \sigma(x)) \quad (3)$$

$$\begin{aligned}
d^2f(x) &= d\left(\left\langle -\frac{1}{m}A^T(b \odot \sigma(-b \odot Ax)) + \lambda x, dx_1 \right\rangle\right) = \\
&= \left\langle \frac{1}{m}A^T\left(b \odot \sigma(-b \odot Ax) \odot (1 - \sigma(-b \odot Ax)) \odot b \odot Adx_2\right) + \lambda dx_2, dx_1 \right\rangle = \\
&= \left\langle \left(\frac{1}{m}A^T\Sigma A + \lambda I_n\right)dx_2, dx_1 \right\rangle, \quad (4)
\end{aligned}$$

где  $\Sigma = \text{diag}\left[\sigma(-b_i \langle a_i, x \rangle)\left(1 - \sigma(-b_i \langle a_i, x \rangle)\right)\right]_{i=1}^n$  – диагональная матрица. Итого:

$$\nabla f(x) = -\frac{1}{m}A^T(b \odot \sigma(-b \odot Ax)) + \lambda x. \quad (5)$$

$$\nabla^2 f(x) = \frac{1}{m}A^T\Sigma A + \lambda I_n. \quad (6)$$

### 3 Эксперимент: Траектория градиентного спуска на квадратичной функции

Необходимо проанализировать работу градиентного спуска для разных квадратичных функций для различного выбора стратегий и для различного начального приближения.

В качестве квадратичной функции выступает  $f(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle$ . Во всех экспериментах  $b = (0, 0)^T$

В первом случае была выбрана функция с единичной матрицей  $A$ . Были выбраны  $x_0 = (4, 4)^T$ ,  $x_0 = (1, 1)^T$ . На Рис. 1 константная стратегия, на Рис. 2 — стратегия Армихо, на Рис. 3 — стратегия Вульфа.




Рис. 1: Константный шаг. Одной строке соответствует одно начальное приближение, каждый столбец соответствует выбору длины шага.

В качестве сетки для константного шага были выбраны следующие значения: 0.01, 0.1, 1.0. По рисунку видно, что чем меньше шаг, тем больше нужно сделать итераций для сходимости, однако ясно, что если шаг будет слишком большим, то метод может не сойтись (см. в разделе с подбором длины шага). Видно также, что метод не зависит от начального приближения.

В стратегии Армихо выбрана следующая сетка для константы  $c_1$ : 0.4, 0.1, 0.0001. Как видно из рисунка метод делает один шаг и благополучно сходится вне зависимости от начального приближения.




Рис. 2: Стратегия Армихо. Одной строке соответствует одно начальное приближение, каждый столбец соответствует выбору константы  $c_1$ .




Рис. 3: Стратегия Вульфа. Одной строке соответствует одно начальное приближение, каждый столбец соответствует выбору константы  $c_2$ .

В стратегии Вульфа константа  $c_1 = 0.0001$  и не меняется, а константа  $c_2$  пробегает по следующей сетке: 0.9, 0.1, 0.01. Как и методы со стратегией Армихо здесь видна сходимость за одну итерацию.

В качестве следующей квадратичной задачи была выбрана матрица  $A$ :  $a_{1,1} = a_{2,2} = 1$ ,  $a_{2,1} = a_{1,2} = 0.9$ . На Рис. 4, 5, 6 представлены соот-

ветственно константная стратегия, стратегия Армихо и Вульфа. Были выбраны следующие начальные приближения:  $x_0 = (0, 4)^T$ ,  $x_0 = (4, 3)^T$ . Сетка для константной стратегии не изменилась, выбор констант для стратегий Армихо и Вульфа такая же как и для первой задачи.




Рис. 4: Константный шаг. Одной строке соответствует одно начальное приближение, каждый столбец соответствует выбору длины шага.




Рис. 5: Стратегия Армихо. Одной строке соответствует одно начальное приближение, каждый столбец соответствует выбору константы  $c_1$ .

Видно, что в константной стратегии выбор начального приближения играет важную роль. Чем лучше начальное приближение, тем меньше итераций необходимо. Также можно заметить, что с возрастанием длины шага уменьшается количество итераций.

В стратегии Армихо количество итераций зависит от начального приближения и от константы  $c_1$ . Чем меньше данная константа, тем больше нужно итераций для сходимости.

В стратегии Вульфа чем меньше константа  $c_2$ , тем меньше нужно итераций для сходимости. Также видно, что эта стратегия не зависит от выбора начального приближения, как стратегия Армихо.




Рис. 6: Стратегия Вульфа. Одной строке соответствует одно начальное приближение, каждый столбец соответствует выбору константы  $c_2$ .

Во второй квадратичной задаче видна зигзагообразная траектория метода градиентного спуска.

## 4 Эксперимент: Зависимость числа итераций градиентного спуска от числа обусловленности и размерности пространства

В данном эксперименте необходимо было для квадратичной задачи показать зависимость между различным выбором числа обусловленно-

сти  $\kappa$  и размерности пространства с числом итераций. Матрица  $A$  диагональная, где  $\kappa = \max_i a_{ii}$ ,  $\min_i a_{ii} = 1$ , а остальные элементы заполнены случайными числами от 1 до  $\kappa$ ;  $b$  — случайный вектор. В качестве начального приближения берется  $x_0 = 0$ . По сетке  $[2, 1000]$  перебирается значение  $\kappa$ ,  $n \in \{10, 100, 1000, 10000, 100000\}$  и эксперимент перезапускается 3 раза, так как каждая генерация квадратичной задачи случайна. На Рис. 7 представлен результат эксперимента.




Рис. 7: Зависимость между количеством итераций против числа обусловленности и размерности пространства. Жирным выделено среднее количество итераций по трём перезапускам.

Видно, линейная зависимость между количеством итераций и числом обусловленности. Также заметно, что количество итераций для разных размерностей не сильно отличаются. Чем больше размерность, тем более зависимость становится похожей на линейную.

## 5 Эксперимент: Сравнение методов градиентного спуска и Ньютона на реальной задаче логистической регрессии

В данном эксперименте необходимо было решить задачу логистической регрессии с  $l_2$ -регуляризатором для трех наборов данных: w8a, gisette, real-sim. Предлагается решать задачу с помощью метода градиентного спуска и метода Ньютона, чтобы сравнить их реальное время работы.

Нужно было построить графики сходимости следующих двух видов:

- Зависимость значения функции от реального времени работы метода.
- Зависимость относительного квадрата нормы градиента  $\frac{\|\nabla f(x_k)\|_2^2}{\|\nabla f(x_0)\|_2^2}$  в логарифмической шкале против реального времени работы.

Графики для датасетов представлены на Рис. 8, 9, 10




Рис. 8: Датасет w8a.

Для датасета w8a видно, что сначала метод Ньютона уступает по реальному времени работы и по скорости сходимости, но затем начинает сходится быстрее.

Running on gisette\_scale dataset ( $m = 6000$ ,  $n = 5000$ )




Рис. 9: Датасет gisette.

Running on real-sim dataset ( $m = 72309$ ,  $n = 20958$ )




Рис. 10: Датасет real-sim.

В датасетах gisette, real-sim не наблюдается картины как на датасете w8a, так как метод градиентного спуска работает быстрее из-за того не нужно на каждой итерации решать систему уравнений с гессианом, как

в методе Ньютона. Также видно, что кривая метода Ньютона сдвинута — это из-за подсчета гессиана в данной точке. Тем самым сложность одной итерации градиентного спуска складывается только из сложности подсчета градиента  $O(mn)$ , а в памяти нужно хранить градиент  $O(n)$  и матрицу  $A$   $O(mn)$ . Для метода Ньютона сложность складывается из сложности подсчета гессиана  $O(mn^2)$ , сложности подсчета градиента  $O(mn)$ , сложности решения системы уравнения с гессианом  $O(n^3)$ , в памяти необходимо хранить гессиан и градиент, что в сумме составляет  $O(n^2)$ , а также матрицу  $A$   $O(mn)$ .

Для градиентного спуска: сложность  $O(mn)$ , память  $O(mn)$ .

Для метода Ньютона: сложность  $O(mn^2 + n^3)$ , память  $O(n^2 + mn)$ .

## 6 (Бонусная часть) Эксперимент: Оптимизация вычислений в градиентном спуске

В данном эксперименте необходимо было сравнить работу метода с оптимизированным оракулом логистической регрессии и обычным по трем графикам:

- Зависимость значения функции от номера итерации.
- Зависимость значения функции от реального времени работы метода.
- Зависимость относительного квадрата нормы градиента  $\frac{\|\nabla f(x_k)\|_2^2}{\|\nabla f(x_0)\|_2^2}$  в логарифмической шкале против реального времени работы.

Графики представлены на Рис. 11




Рис. 11: Сравнение между оптимизированным оракулом и обычным.

По графикам видно, что оптимизированный оракул работает гораздо быстрее, так как не нужно каждый раз тратить  $O(mn)$  для подсчет  $Ax_k$  и  $Ad_k$  в линейном поиске. Также по первому видно, что оптимизированный оракул работает также как и обычный по итерациям, так как оптимизируется сама процедура линейного поиска, а  $\alpha_k$  при этом остается таким же как и при обычном оракуле, иными словами оптимизируется время, а не количество итераций.

## 7 (Бонусная часть) Эксперимент: Стратегия выбора длины шага в градиентном спуске

В данном эксперименте необходимо было показать влияние стратегии длины шага на скорость сходимости по невязке функции в квадратичной задаче и на скорость сходимости по относительной норме градиента в задаче логистической регрессии. Нужно было попробовать разные начальные приближения.




Рис. 12: Квадратичная задача.

Видно, что метод очень чувствителен к выбору константного шага. При увеличении  $c$  уменьшается количество итераций, и при  $c = 0.06$  метод сходится достаточно хорошо, а при  $c = 0.07$  уже полностью расходится. Адаптивные стратегии сами подбирают нужный шаг и сходят гораздо быстрее. При увеличении константы  $c_2$  в стратегии Вульфа увеличивается скорость сходимости. Стратегии Армijo с разными константами работают примерно одинаково.




Рис. 13: Квадратичная задача.

В задаче логистической регрессии также видно, что константная стратегия при больших  $c$  расходится, а при маленьких сходится очень медленно. В стратегии Армихо при увеличении  $c_1$  уменьшается скорость сходимости. Стратегии Вульфа работают одинаково.




Рис. 14: Задача логистической регрессии.




Рис. 15: Задача логистической регрессии.

## 8 (Бонусная часть) Эксперимент: Стратегия выбора длины шага в методе Ньютона

В данной части необходимо повторить эксперименты предыдущего пункта для метода Ньютона.




Рис. 16: Квадратичная задача.

Видно, что при маленькой константе в константном варианте, метод сходится очень долго, а при константе  $c = 1.0$  сходится за одну итерацию и видна почти линейная сходимость. Стратегии Армихо и Вульфа сходятся также за одну-две итерации.

В задаче логистической регрессии адаптивные стратегии не сильно отличаются друг от друга и видна квадратичная сходимость. Для константного выбора шага при  $c > 1.0$  метод начинает расходиться, а при остальных  $c$  сходится довольно медленно.




Рис. 17: Квадратичная задача.




Рис. 18: Задача логистической регрессии.




Рис. 19: Задача логистической регрессии.

## 9 Выводы

По графикам можно сделать следующие выводы:

- Методы с адаптивной стратегией сходятся быстрее, подбирая на каждой итерации нужный шаг.
- Градиентный спуск работает быстрее, чем метод Ньютона по времени, где имеется огромная размерность пространства. Однако метод Ньютона сходится быстрее, чем градиентный спуск в задачах с малым количеством признаков
- При увеличении размерности пространства количество итераций градиентного спуска для различных чисел обусловленности остается одинаковым.